



科技爱好者周刊#408：你需要知道的 AI 缓存知识

原创 阮一峰 阮一峰的网络日志 2026年08月14日 08:43 云南

这里记录每周值得分享的科技内容，周五发布。

本杂志 [开源](#) ^[1]，欢迎 [投稿](#) ^[2]。另有 [《谁在招人》](#) ^[3] 服务，发布程序员招聘信息。合作请 [邮件联系](#) ^[4]（yifeng.ruan@gmail.com ^[5]）。

封面图



浙江台州的椒江滨江公共空间生态绿廊，象征涟漪从水面蔓延，涌上岸边，堆积成丘。（[via](#) ^[6]）

你需要知道的 AI 缓存知识

大模型的价格，主要是 Token 的输入价格和输出价格，这个很容易理解。

但是，还有一项“输入 Token 的缓存命中价格”，这是什么东西？

价格(2)	百万tokens输入 (缓存命中)	0.02元
	百万tokens输入 (缓存未命中)	1元
	百万tokens输出	2元

上图是 DeepSeek V4 Flash 模型的 [定价](#) [7]，可以看到缓存命中的输入价格只有2分钱，足足是未命中的输入价格的五分之一！

为什么相差这么大？我们能不能充分利用缓存，来降低费用呢？

我对于这些问题，以前也不是很了解，最近看了 [一篇文章](#) [8]，终于理清了思路，今天就来分享。

(1) 模型输入的收费原因

大家知道，使用大模型的时候，需要先有提示词。

大模型会将提示词分解成 Token，再将 Token 转成向量值，然后计算所有 Token 之间的注意力关系。

这一步非常消耗算力，因此模型公司会对输入 Token 收费。你的提示词越多，输入 Token 的费用就越高。

(2) 输入缓存的作用

对于多轮对话和长程任务，每一轮都需要把以前步骤的输入输出结果，提交给模型。

我们可以想到，这些每一轮额外增加的提示词是不变的，以前都已经处理过了。模型完全不必要对这些“前缀”每次进行重复计算，只要把以前的计算结果缓存起来，下一次再取出来用就行了。

这就是为什么需要缓存，它可以大大节省不必要的算力消耗，加快模型处理。

这也是它便宜的原因，因为只要命中缓存，基本不消耗算力，收取的费用实际上是储存空间的费用。

(3) 缓存的时间期限

缓存有时间期限，长期保存并无意义。如果一段时间没有用到这些缓存，服务器就会把缓存删除。

根据 [前面引用文章](#) [9] 的测试，各家公司的缓存保存时间不一样。

- Anthropic: 5分钟
- DeepSeek: 10分钟
- OpenAI: 10分钟~30分钟逐步失效
- Google: 1小时内逐步失效

以 DeepSeek 为例，在10分钟以内，缓存就是有效的，命中缓存只收取2分钱。如果对话的间隔特别久，下一次输入跟上一次之间超过了10分钟，缓存就被删除了，模型收到上一轮的提示词，就不得不重新计算，收取的费用就变成了1元。

(4) 保持缓存有效

由于缓存命中与未命中之间，有巨大的价差。用户的 AI Agent 工具往往会想办法，尽可能延长缓存的保存时间。

当用户长时间不操作、也不退出的时候，大多数 AI Agent 会每隔30秒，自动向服务器发送一个请求，让缓存保存激活状态。

有些模型有专门的缓存激活接口，还有一些没有。这时可以用笨办法，Agent 自动重复发送一次以前的提示词，确保缓存激活。


不过，激活请求也会产生费用。每隔30秒发送一次，如果10分钟没有输入，就会发送20个激活请求。时间一长，费用也不低。

前面说过了，现在各家模型的实际缓存期限，最短也有5分钟，因此30秒一次的激活请求，似乎频率太高了。所以，最新的建议是，可以改成每4分钟自动激活一次缓存。

科技动态

1、带蓝牙识别的交通摄像头 [10]

一家美国创业公司推出一种交通摄像头，不仅能识别车牌号，还能识别蓝牙设备。



公路上的交通摄像头，一般来说只能拍到车牌，不能识别谁在开车。

这个新型摄像头就能解决这个问题。它还能捕捉蓝牙信号，从而将蓝牙设备的 MAC 地址跟车牌绑定，有助于推断谁在车上。

此外，除了蓝牙，它还能捕捉钥匙卡和宠物芯片中的 RFID 标签，以及车内 WIFI 的 SSID，从而进一步增加推断的可靠性。

2、声波灭火 [11]

灭火除了用水，还可以用声波。

物理学已经证明，强烈的低频声波（30Hz ~ 60Hz）可以用来灭火，原理是声波可以阻碍氧气流入，并加速热量散发。



一家美国创业公司，最近就制造了一个声波灭火装置，准备推广上市。他们成功演示了厨房灭火的场景。



只见喇叭对着灶头猛放低频声波，火就灭了。该公司希望该装置可以取代喷淋系统，以后着火时，头顶的喇叭放声音就可以了。

但是，它有几个缺点，可能难以推广。首先，喇叭的体积较大，否则声波强度不够，另外它必须离火源较近，因为声波会迅速衰减。这也造成它只能用于零星的火势，无法用于连片的大火。

3、没有舷窗的飞机^[12]

一家美国的飞机制造商，推出新型的私人飞机，最大特点是没有舷窗（下图）。




它的机舱内部是一体封闭的，没有窗户。

取而代之的是，连在一起的液晶显示屏，播放飞机外部的高分辨率摄像头拍到的景象。

该公司表示，取消窗户可以让飞机更轻，外表更光滑，从而减少空气阻力和燃油消耗。而且，乘客不必探头，就能在座位上环顾整个高空，拥有飞机驾驶员的视野，而不是原来窗口的狭小视野。

4、最长的视线 [13]

科学家使用算法，确定了地球上最长的视线，即从一个地点可以看到另一个地点的最长距离。



那是从吉尔吉斯斯坦（靠近中国边境）的皮克丹科瓦峰向南眺望，可以清晰地看到中国昆仑山脉深处，距离长达530公里。

一般来说，海拔越高、空气越通透，看的距离就越远。

皮克丹科瓦峰海拔约6000米，向南正好是低洼的柴达木盆地沙漠，再远又是海拔6000米以上的昆仑山，因此，这两座相距几百公里的高山可以互相眺望。

文章

1、常见的任务执行工具 [14] (英文)



命令行执行任务，可以选择不同的执行方式，比如自己写 Bash 脚本，或者用 make、just、mise 等任务执行工具。

2、如何用脚本将文件上传到 GitHub [15] (英文)



curl -s -H "https://uploads.github.com/user/attachments/assets?name=BP111" -X POST -d "function=can" -m "honey" -u "honey"

GitHub 允许用户上传文件到 issue 和 pull request，本文教你怎么在脚本里面上传。

3、Canvas 而不是 HTML [16] (英文)



很多复杂网页不使用 HTML，而使用 Canvas 呈现页面，用户看到的其实是一张图片。本文讨论 Canvas 页面的优缺点，以及何时适用。

4、我的服务器是一部手机 [17] (英文)



作者介绍怎么把自己的安卓手机作为 Linux 服务器（使用了 Termux）。


"（我的安卓手机有）八个 ARM 核心、8GB 内存、128GB 闪存、WiFi 6、5G 调制解调器，以及内置电池，所有这些集成在一个我觉得性能过剩、闲置在抽屉里的 SoC 芯片上。而且我已经付过钱了。掸去灰尘，把玩了一会儿之后，我决定把这台手机改造成服务器。"

5、电梯的算法 [18] (英文)




本文介绍电梯的算法，写得比较简单，没有代码实例，但有动画，解释了这个问题的复杂性在哪里（如何缩短等待时间）。

1、Docker 沙箱 [19]




Docker 官方推出的沙箱工具，把 Docker 容器当作沙箱，让 AI Agent 在里面运行，跟底层系统隔离。

2、CertMate [20]



一个自搭建的 SSL 证书管理系统，可以自动申请证书，支持多家云服务商。

3、crontab guru Dashboard [21]




这个工具让你用图形界面，来管理 Cron 任务。

4、trash-cli [22]

一个 Linux 命令行程序，提供回收箱功能，保存已删除的文件，以备将来恢复，参考 [介绍文章 \[23\]](#)。

5、LeePanel [24]



安装在本地计算机的远程服务器管理面板，所有操作都由 SSH 操作完成，不需要在服务器安装任何东西。（[@gna1280072 \[25\]](#) 投稿）

6、MarkCard Studio [26]




将 Markdown 文本转成分享卡片，提供16套内置主题，可以自动分页、排版，一次导出整套图片或 PDF。（[@pangxiaobin \[27\]](#) 投稿）

7、日全食 3D 模拟器 [28]



在地图上模拟2026年8月12日的日全食，查看指定地点什么时候开始日食、食甚和结束，以及天空的样子。（[@DophinL \[29\]](#) 投稿）


8、DBX [30]



轻量级跨平台的数据库管理工具，支持79余种数据库，并且可以接入 AI 与 MCP。（[@t8y2 \[31\]](#) 投稿）

AI 相关

1、Cloudflare OS [32]




Cloudflare 本周开源了一个内部的 AI 工具，虽然名字里面有 OS，但其实是在浏览器里使用。
它是一个企业内部的 AI 门户，用来向员工提供统一的 AI 服务，包括 AI 代理、内部应用、知识管理和自动化流程。

2、乡音阁 [33]



在线文字转方言语音工具，目前支持16种方言、63个音色。（@ldbmcs [34] 投稿）

3、chat.md [35]



一个 VS Code 插件，将 AI 对话框变成一个 Markdown 文件，用户的输入和 AI 的输出都自动显示在这个文件。


4、Parse [36]



该网站让你使用自然语言，抓取其他网站的数据，转为 API 输出，免费额度是每分钟5个请求。


资源

1、昆虫世界 [37]




60 种昆虫的 3D 图鉴，可以旋转、缩放、点击标注点，介绍昆虫的身体构造、生活史与生态角色。（@xr843 [38] 投稿）

2、图解分布式系统原理 [39]（中文）



本系列采用图示和直观解释的方式，深入探讨分布式系统背后的核心思想。（@lichuang [40] 投稿）

3、吹口哨练习器 [41] (HowToWhistle)





练习吹口哨的在线工具，实时检测你吹出的音高，显示当前音符以及与目标音的偏差。（@0647-cyber [42] 投稿）

图片

1、回形针收藏 [43]

一个美国收藏家专门收藏回形针。这些藏品放在一起，还有一点艺术感。



2、古典雕像的彩绘^[44]

很多东西没有装饰时，比有装饰更漂亮。

希腊罗马雕塑现在显得非常高雅，但是它们最初都有彩绘，看上去非常俗艳。



上图是罗马皇帝奥古斯都的雕像，它最初制作的时候是有彩绘的。



文摘

1、[荷兰和中国](#) ^[45] (英文)

我是荷兰人，在中国生活了八年。那些日子里，出租车司机和同事总爱问我：“荷兰和中国哪个更好？”

现在，我回到荷兰定居，人们却反过来问我：想念中国的生活吗？

这两个问题都不容易回答。这是两种不同的生活，很难比较。

住在上海的时候，我曾经瞧不起荷兰那些老旧的科技——银行卡、政府的纸质信件、乏善可陈的基础设施。回到荷兰后，我也确实怀念中国豪华的电动汽车，以及便捷的换电功能。但是，荷兰的自行车基础设施实在太棒了，而且阳光明媚的日子里骑车出行乐趣无穷。

大多数荷兰人比上海人富裕，但家中却没有空调，他们开着更小、更老旧、配置更少的汽车。公共交通相比之下糟糕透顶。手机更小、分辨率更低、速度更慢——电视也是如此。商店周日关门，人们仍然使用现金或银行卡支付。

有一次，我想打电话给我的荷兰银行，在它的网站上费了九牛二虎之力才找到电话号码，然后电话排队等上15分钟才能问到一个10秒钟就能解决的问题。而在中国，银行 App 里就有聊天功能，可以立即联系到客服人员。

荷兰的公共厕所也比较少，因为维护成本太高，政府不愿意为此买单。私人保姆或清洁工也少得多，因为价格极其昂贵，我们只能重新开始全职在家做饭，外出就餐很贵，外卖选择也很少，而且送餐速度很慢。

但是，荷兰人有更多的空闲时间，而且住的房子更大，通常前后院都有草坪。由于物价更高（包括商品和劳动力），荷兰的二手市场规模更大——自行车、汽车、家具等等，物品必须回收利用、修理或尽可能延长使用寿命。

在上海，我们会在网上购买婴儿用品，阅读关于最新款玩具或带有人工智能功能的婴儿摄像头的介绍。而在荷兰，我的父母仍然保留着我小时候用过的玩具、婴儿床和餐具——三十多年后的今天，我的小孩还在用。

总的来说，荷兰是一个规模较小、技术水平较低的社会。规模小体现在市政厅只有一个办公窗口，而上海却有数百个市民服务中心，每个中心都设有数十个服务台。据我所知，我生活的小镇只有一台自动取款机和一个小型图书馆。

在我看来，荷兰是一个拥有充裕时间的国度，人民过着节俭的生活，而中国是一个急切变革的国度，迅捷而急躁，人们争先恐后争取自己的机会。

回到最初的问题——荷兰和中国哪个更好——我的回答依然是，这两个国家各有自己的长处和不足，两种生活截然不同。

言论

1、

AI 省下的时间，不是用来休闲的，而是应该用来开发更多产品。你们正在做这个星球上最令人兴奋的事情。

-- [Andrew Bosworth \[46\]](#)，Meta 公司 CTO 回答员工的提问，关于 AI 带来的生产力提升是否可以转化为更多的休闲时间的。

2、

一些人试图将蒸馏描述为有害行为，但我认为，应当保护“可以从任何能够观察到的事物中学习”这一原则。

-- [扎克伯格 \[47\]](#)，Meta 公司创始人

3、

有很多理由在本地运行大模型，但省钱不在其中。

目前，OpenCode Go 套餐的用户，平均每天花费1.14美元，来运行 DeepSeek Flash v4。同样的功能在本地运行，你需要使用双 DGX 架构，即使每天费用翻上10倍，也需要 24 年才能收回成本。

-- [Dax Raad \[48\]](#)，OpenCode 创始人

4、

你不接受某种想法，但仍然愿意对其进行思考，这是受过良好教育的标志。

往年回顾

暗网 Tor 安全吗? [50] (#361)

低利率与长期项目 [51] (#311)

黑客马拉松的正确方式 [52] (#261)

虚拟商品可以拉动 GDP [53] (#211)

(完)

References

- [1] 开源: <https://github.com/ruanyf/weekly>
- [2] 投稿: <https://github.com/ruanyf/weekly/issues>
- [3] 《谁在招人》: <https://github.com/ruanyf/weekly/issues/10950>
- [4] 邮件联系: <mailto:yifeng.ruan@gmail.com>
- [5] yifeng.ruan@gmail.com: <mailto:yifeng.ruan@gmail.com>
- [6] via: <https://www.gooood.cn/en/ripples-becoming-everyday-ground-by-original-design-studio-tjad.htm>
- [7] 定价: https://api-docs.deepseek.com/zh-cn/quick_start/pricing/
- [8] 一篇文章: <https://blog.mempko.com/your-agentic-workflows-cache-keepalive-costs-8x-too-much-v2-the-interval-frontier/>
- [9] 前面引用文章: <https://blog.mempko.com/your-agentic-workflows-cache-keepalive-costs-8x-too-much-v2-the-interval-frontier/>
- [10] 带蓝牙识别的交通摄像头: <https://www.404media.co/this-company-will-add-phone-airpod-and-smartwatch-trackers-to-license-plate-readers/>
- [11] 声波灭火: <https://arstechnica.com/gadgets/2026/05/startup-says-sound-waves-can-replace-fire-sprinklers-experts-arent-so-sure/>
- [12] 没有舷窗的飞机: https://www.wsj.com/business/airlines/this-windowless-plane-is-vying-to-be-the-private-jet-of-the-future-2fdf184b?st=fHNiyn&mod=1440&user_id=66c4c9305d78644b3ac5df9c
- [13] 最长的视线: <https://earthlymission.com/longest-view-world/>
- [14] 常见的任务执行工具: <https://hamvocke.com/blog/task-runners/>
- [15] 如何用脚本将文件上传到 GitHub: <https://island94.org/2026/08/programmatically-upload-attachments-to-github-issues-pull-requests-comments>
- [16] Canvas 而不是 HTML: <https://hivekit.io/blog/why-you-might-want-to-build-your-webapp-in-canvas-instead-of-html/>
- [17] 我的服务器是一部手机: <https://seg6.space/posts/phone-server/>
- [18] 电梯的算法: <https://john.fun/elevators>
- [19] Docker 沙箱: <https://www.docker.com/products/docker-sandboxes/>
- [20] CertMate: <https://github.com/fabriziosalmi/certmate>
- [21] crontab guru Dashboard: <https://crontab.guru/dashboard.html>
- [22] trash-cli: <https://github.com/andreafrancia/trash-cli>
- [23] 介绍文章: <https://ittavem.com/adding-a-trash-can-to-linux-with-trash-cli/>
- [24] LeePanel: <https://github.com/gna1280072/LeePanel>
- [25] @gna1280072: <https://github.com/ruanyf/weekly/issues/11083>
- [26] MarkCard Studio: <https://github.com/pangxiaobin/MarkCardStudio>
- [27] @pangxiaobin: <https://github.com/ruanyf/weekly/issues/11097>
- [28] 日全食 3D 模拟器: <https://github.com/DophinL/solar-eclipse-2026-simulator>
- [29] @DophinL: <https://github.com/ruanyf/weekly/issues/11136>
- [30] DBX: <https://github.com/t8y2/dbx>
- [31] @t8y2: <https://github.com/ruanyf/weekly/issues/11143>

- [32] Cloudflare OS: <https://github.com/cloudflare/cloudflare-os>
- [33] 乡音阁: <https://xiangyinge.com/zh>
- [34] @ldbmc: <https://github.com/ruanyf/weekly/issues/11111>
- [35] chat.md: <https://github.com/rusiaaman/chat.md>
- [36] Parse: <https://www.parse.bot/>
- [37] 昆虫世界: <https://github.com/xr843/insect-world>
- [38] @xr843: <https://github.com/ruanyf/weekly/issues/11135>
- [39] 图解分布式系统原理: <https://github.com/ruanyf/weekly/issues/11121>
- [40] @lichuang: <https://github.com/ruanyf/weekly/issues/11121>
- [41] 吹口哨练习器: <https://howtowhistle.org/zh>
- [42] @0647-cyber: <https://github.com/ruanyf/weekly/issues/11127>
- [43] 回开列收藏: <https://www.presentandcorrect.com/blogs/blog/david-walkers-paper-clip-collection>
- [44] 古典雕像的彩绘: <https://worksinprogress.co/issue/were-classical-statues-painted-horribly/>
- [45] 荷兰和中国: <https://jaapgrolleman.com/degrees-of-wealth/>
- [46] Andrew Bosworth: <https://finance.sina.cn/7x24/2026-08-09/detail-inimsssr1991323.d.html>
- [47] 扎克伯格: <https://finance.sina.cn/7x24/2026-08-11/detail-inimxmq5879406.d.html>
- [48] Dax Raad: <https://x.com/thdxr/status/2086599224674681242>
- [49] 亚里士多德: <https://www.campion.edu.au/blog/top-25-aristotle-quotes-on-virtue-knowledge-and-happiness/>
- [50] 暗网 Tor 安全吗? : <https://www.ruanyifeng.com/blog/2025/08/weekly-issue-361.html>
- [51] 低利率与长期项目: <https://www.ruanyifeng.com/blog/2024/08/weekly-issue-311.html>
- [52] 黑客马拉松的正确方式: <https://www.ruanyifeng.com/blog/2023/07/weely-issue-261.html>
- [53] 虚拟商品可以拉动 GDP: <https://www.ruanyifeng.com/blog/2022/06/weekly-issue-211.html>

[阅读原文](#) [阅读](#)

精选留言



人社局李姜志15848089480 来自内蒙古

“不接受某种想法，但仍然愿意对其进行思考”现在就这样训练自己，非常难但是值得试试



晓 来自湖北

如果人人都这样，网络世界就一片祥和了。



踩马路 来自河南

新鲜新鲜就好，这种思考会极大的浪费时间和机会。



行路远 来自陕西

我以前一个同事嫁到荷兰去了，看着她发的朋友圈，是挺悠闲的。划船，骑自行车，大别墅



Zhangyg 来自北京

回农村也优先的类 整体还是因为中国相对来说上升期 到期大家都很卷



京都念慈 来自广东

农村生活也有农村生活的好。



HYC 来自重庆

中国的农村生活也是可以的，有舍有得，需要自己选择



牛仔酷 来自云南

去大理也可以，晒晒太阳，发发呆，骑骑车，划划水，一切都可以慢下来



Chen, Zhuohui 来自

北欧的生活，确实相对世界绝大部分地区悠闲[睡]



Steve 来自上海

欧洲的悠闲是建立在未来的落后上的



进道如退 来自湖北

世界上第一家股份制公司，股票交易所在荷兰诞生，彼时中国还在明朝万历年间。荷兰东印度公司当初在全球赚走了大把钞票，现在靠遗产也能活得很滋润。



肤浅 来自陕西

Dax Raa 的说法在昨天过时了，deepseek 涨价了最高 12 倍，所以本地部署可能两年就可以回本。



Panzer Vor 来自福建

ai 提效的时间不应该用来休假这个我反对。照这个逻辑，人就不需要休假，满足生命需求后一直创造不好吗。休假本身就是为了更好的创造。



holoalala 来自江苏

火灾伤害比较大的其实是烟雾



阿哲 来自北京

请问英文网页是用什么插件翻译的



志洪同学 来自广东

沉浸式翻译，或者 trancy 都可以



sonson 来自海南

唯一限制我工作时间的是5小时额度限制～



NEAL WANG 来自江苏

把手机当做服务器还有一个额外的好处，自带UPS



Chen, Zhuohui 来自

缓存是个很有用的功能，但我没想到原来时间这么短。



Cheezay 来自福建

声波灭火这块，可以看看毕导做过一期视频，比想象的有意思



欢城(Ray) 来自福建

通俗易懂



灰太mo 来自广东

现在加的AI科普知识好评[强]



Wow. 来自山东

之前做过trash-cli同款，py-recycle



夏天 来自湖北

有意思，如果没有操作得定期更新缓存，提示词就写：

这只是一个更新缓存的请求，返回 ok 就行，不需要工具调用，后面步骤忽略掉。



爱飙车的老法师 来自辽宁

@元宝国内各家大模型公司的缓存保存时间是多少



元宝 来自广东

文章中提到DeepSeek的缓存保存时间为10分钟。其他国内大模型公司的具体缓存时间未在文中说明，各家策略会根据技术架构和成本考量有所不同。